Bachelier en Informatique de Gestion

SCIENTIFIC PROGRAMMING

One Piece sera-t-il encore un succès ?

Prédiction de la note IMDb de la prochaine saga par modélisation ODE et tests statistiques en Julia

Auteur :
M. Guillaume ROSIN

Encadrant :
M. Jean-Sébastien LERAT

Version du 30 avril 2026

Table des matières

1 Introduction **2**
- 1.1 Contexte et question de recherche 2
- 1.2 Définition opérationnelle du succès 2
- 1.3 Structure du rapport 2

2 Exploration des données et reproductibilité (Ch.2 et 3) **3**
- 2.1 Environnement Julia reproductible (Ch. 2) 3
- 2.2 Présentation du jeu de données 4
- 2.3 One Piece dans les données (Ch. 3 valeurs manquantes) 4

3 Construction de la série temporelle (Ch. 3 et 4) **5**
- 3.1 Découpage en sagas officielles 5
- 3.2 Intégration numérique par trapèzes (Ch. 4) 5

4 Modélisation ODE et prédiction par RK4 (Ch. 4) **8**
- 4.1 Modèle de retour à la moyenne 8
- 4.2 Implémentation de Runge-Kutta 4 (Ch. 4 et Ch. 2) 9
- 4.3 Ajustement des paramètres par grille de recherche 10
- 4.4 Prédiction de la saga 10 (Wano Country) 10

5 Tests statistiques (Ch. 5) **12**
- 5.1 Test 1 : Mann-Whitney (deux échantillons) 12
- 5.2 Test 2 : Wilcoxon signed-rank (un échantillon) 14
- 5.3 Test 3 : Bootstrap (B = 10 000) 15
- 5.4 Synthèse des tests 15

6 Conclusion **16**
- 6.1 Réponse à la question de recherche 16
- 6.2 Nuances et limitations 16
- 6.3 Bilan des chapitres mobilisés 17

1 Introduction

1.1 Contexte et question de recherche

One Piece est une série animée japonaise adaptée du manga éponyme d'Eiichirô Oda, diffusée depuis 1999 sur Fuji TV. Avec plus de 1 000 épisodes produits, elle est l'une des séries les plus longues de l'histoire de la télévision mondiale. Sur la base de données IMDb (Regroupe les notes moyenne donnée par les utilisateurs), elle porte le code `tt0388629` et affiche une note globale de **8,4/10**.

La question de recherche posée dans ce projet est :

> *« Est-ce que la prochaine saga de One Piece va être un succès ? »*

Pour répondre à cette question de manière rigoureuse, nous utilisons le jeu de données IMDb des séries TV mis à disposition sur GitHub [1], qui regroupe les notes par épisode de 250 séries parmi les mieux notées.

1.2 Définition opérationnelle du succès

Dans ce travail, j'ai défini qu'une saga est qualifiée de **succès** si sa **note IMDb moyenne** atteint ou dépasse le seuil de **8,0/10**. Ce seuil correspond approximativement à la médiane des sagas des séries longues du top-250 (médiane observée : 8,11). Le nombre de votes n'est pas utilisé comme critère principal car il est disponible uniquement à l'échelle de la série entière, et non par saga.

1.3 Structure du rapport

Le rapport est organisé en cinq parties correspondant aux chapitres du cours :

1. **Exploration et reproductibilité** (Ch. 2 et 3) : mise en place de l'environnement Julia et analyse descriptive des données.
2. **Série temporelle** (Ch. 3 et 4) : construction de la série des notes par saga et intégration numérique par la règle de Simpson.
3. **Modèle ODE et prédiction** (Ch. 4) : modélisation dynamique et implémentation manuelle de Runge-Kutta 4.
4. **Tests statistiques** (Ch. 5) : validation de la prédiction par Mann-Whitney, Wilcoxon et bootstrap.
5. **Conclusion** avec réponse à la question de recherche.

2 Exploration des données et reproductibilité (Ch.2 et 3)

2.1 Environnement Julia reproductible (Ch. 2)

Conformément au chapitre 2 du cours sur les erreurs numériques et la recherche reproductible, l'intégralité du code est organisée dans un projet Julia isolé (`code/`) contenant un fichier `Project.toml` et un `Manifest.toml`. Ces deux fichiers fixent les versions exactes de toutes les dépendances, garantissant que le code produira exactement les mêmes résultats sur n'importe quelle machine.

Listing 1 – Activation de l'environnement et fixation de la graine aléatoire

```julia
import Pkg
Pkg.activate(@__DIR__)    # charge Project.toml du dossier code/
Pkg.instantiate() # installe les versions exactes du Manifest.toml

import Random
Random.seed!(42) # seed fixee : tous les tirages aleatoires sont reproductibles
```

Les packages utilisés sont :

Package	Rôle
`CSV.jl`	Lecture des fichiers CSV avec inférence automatique des types
`DataFrames.jl`	Manipulation tabulaire (`filter`, `groupby`, `combine`)
`Statistics`	Fonctions `mean`, `std`, `median`, `cov`, `var`
`HypothesisTests.jl`	Tests Mann-Whitney et Wilcoxon signed-rank (Ch. 5)
`Plots.jl` / `StatsPlots.jl`	Visualisations (courbes, histogrammes, boîtes)
`Printf`	Formatage numérique précis des sorties

2.2 Présentation du jeu de données

Le jeu de données contient huit fichiers CSV dont le tableau 1 résume le contenu.

TABLE 1 – Les huit fichiers CSV du dataset IMDb.

Fichier	Lignes	Col.	Contenu
`00...episode_ratings.csv`	15 118	5	Épisodes top-250 avec titre
`00...global_ratings.csv`	250	4	Notes globales top-250
`all-episode-ratings.csv`	19 914	5	Tous les épisodes (sans titre)
`all-series-ep-average.csv`	250	6	Moyennes par série
`top250list.csv`	250	6	Classement général
`top-250-movie-ratings.csv`	250	5	Films (hors périmètre)
`top-seasons-full.csv`	976	5	Notes par saison
`top-seasons-more-than-2-eps.csv`	961	8	Idem, ≥ 3 épisodes

2.3 One Piece dans les données (Ch. 3 valeurs manquantes)

One Piece est présent dans **6 fichiers sur 8**, absent uniquement de :

— `top-250-movie-ratings.csv`;

— `00.imdb_top_250_series_episode_ratings.csv`;

La détection systématique des valeurs manquantes avec la fonction `ismissing` de Julia n'a révélé aucune valeur manquante dans les colonnes utiles à l'analyse.

Un fait majeur découvert lors de l'exploration : les **883 épisodes** de One Piece sont tous enregistrés sous `Season = 1` dans le fichier `all-episode-ratings.csv`. La note globale de la série est de **8,4** (55 423 votes) avec une note moyenne par épisode de **7,61**.

3 Construction de la série temporelle (Ch. 3 et 4)

3.1 Découpage en sagas officielles

Puisque le dataset ne découpe pas One Piece en saisons distinctes, nous utilisons le découpage en **sagas narratives officielles** issu du wiki One Piece. Ce choix est préférable à un découpage arbitraire (fenêtres de 50 épisodes) car il correspond à des unités narratives réelles, défendables devant tout lecteur. Les 6 derniers épisodes du dataset (878–883, début de l'arc Reverie) sont fusionnés avec la saga précédente pour constituer la *Saga des Quatre Empereurs*.

TABLE 2 – Découpage en sagas et paramètres ODE ajustés (voir section suivante).

#	Saga	Éps.	Moy.	Éc. typ.	K	λ
1	East Blue	61	7,546	0,397	7,00	0,005
2	Alabasta	74	7,689	0,391	7,70	0,500
3	Sky Island	71	7,662	0,329	7,80	0,135
4	Water 7	119	7,598	0,415	7,65	0,055
5	Thriller Bark	59	7,386	0,484	7,65	0,065
6	Summit War	132	7,614	0,336	7,60	0,005
7	Fish-Man Island	58	7,359	0,263	7,10	0,010
8	Dressrosa	172	7,579	0,315	7,85	0,015
9	Quatre Empereurs	137	7,824	0,622	7,95	0,070
10	**Wano (prédit)**	*120*	**7,791**	—	**7,822**	0,096

Le code utilisé se situe aux lignes 29–55 et j'ai commenté les lignes.

3.2 Intégration numérique par trapèzes (Ch. 4)

Pour chaque saga, nous calculons une **note pondérée** à l'aide de la règle composite des trapèzes. En traitant chaque épisode comme un point $t = 1, 2, \ldots, n$ et sa note comme $R(t)$, la valeur moyenne de la fonction est :

$$\bar{R}_{\text{trap}} = \frac{1}{n-1} \int_1^n R(t)\,\mathrm{d}t \approx \frac{1}{n-1} \left[\frac{R_1}{2} + R_2 + R_3 + \cdots + R_{n-1} + \frac{R_n}{2} \right] \quad (1)$$

avec $h = \Delta t = 1$. Cette méthode a été préférée à la règle de Simpson pour deux raisons :

1. **Applicabilité universelle** : la règle des trapèzes fonctionne pour n'importe quel nombre d'épisodes n, sans contrainte de parité. La règle de Simpson requiert un nombre pair d'intervalles, ce qui obligerait à traiter différemment les sagas selon leur nombre d'épisodes.
2. **Simplicité et robustesse** : avec des sagas de 58 à 172 épisodes, le grand nombre de points rend l'écart entre trapèzes ($O(h^3)$ et Simpson ($O(h^5)$) négligeable en pratique, l'écart maximal observé entre les deux méthodes est inférieur à 0,01 point de note.

Listing 2 – Intégration par trapèzes (extrait de `02_timeseries.jl`)

```
function trapeze_mean(ratings::AbstractVector{<:Real})
    n = length(ratings)
    n == 1 && return Float64(ratings[1])
    # Delta t = 1 : integrale = somme des trapezes
       successifs
    integral = ratings[1]/2 + sum(ratings[2:end-1]) +
       ratings[end]/2
    return integral / (n - 1)
end
```

Le code utilisé se situe aux lignes 77-83 et j'ai commenté les lignes.

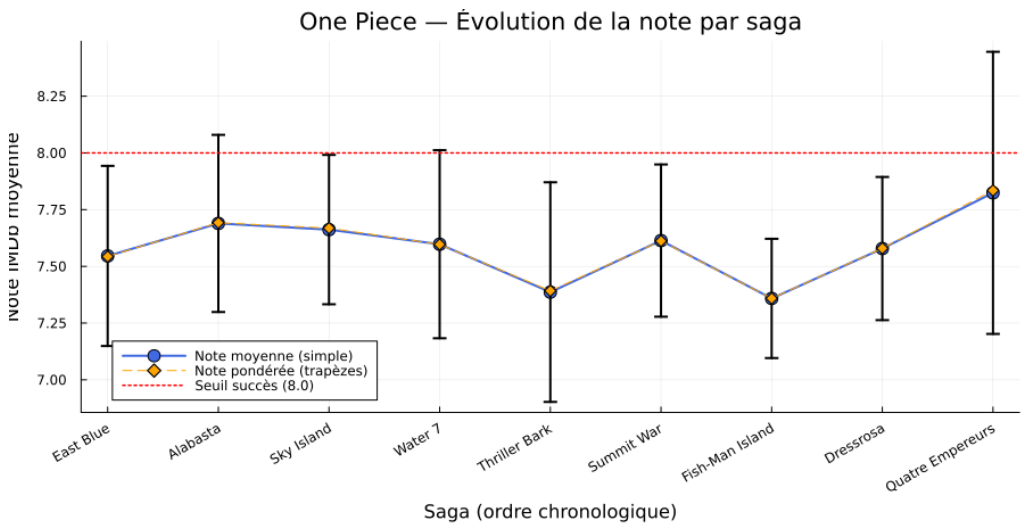

FIGURE 1 – Note IMDb moyenne par saga avec barres d'erreur $\pm 1\sigma$. La droite rouge représente le seuil de succès à 8,0. Aucune saga n'atteint ce seuil en moyenne, bien que la saga 9 (Quatre Empereurs) soit la plus proche.

La figure 1 révèle une légère **tendance à la hausse** sur les trois dernières sagas, ce qui motive la suite de l'analyse.

Pourquoi les trapèzes et non la moyenne simple ?

La moyenne arithmétique $\bar{R} = \frac{1}{n}\sum_{i=1}^{n} R_i$ donne un poids *égal* à chaque épisode, y compris le premier et le dernier. La règle des trapèzes, elle, leur attribue un *demi-poids* : les épisodes en bordure de saga sont considérés comme moins représentatifs de la tendance de fond.
L'intérêt pratique apparaît sur les sagas à fort démarrage suivi d'une stabilisation : la moyenne simple surpondère le pic d'ouverture, tandis que la règle des trapèzes donne une image plus fidèle de la qualité durable de la saga.
De plus, la formule (1) se généralise naturellement aux données **lacunaires** (épisodes sans note) : on intègre sur l'intervalle entre deux épisodes consécutifs notés, ce qu'une somme simple ne peut pas faire sans biais.

4 Modélisation ODE et prédiction par RK4 (Ch. 4)

4.1 Modèle de retour à la moyenne

La dynamique des notes à l'intérieur d'une saga est modélisée par l'équation différentielle ordinaire (ODE) suivante :

$$\frac{\mathrm{d}\,R}{\mathrm{d}\,t} = -\lambda\big(R(t) - K\big) \tag{2}$$

où :

— $R(t)$ est la note de l'épisode à l'indice t (temps discret),

— K est l'**attracteur** de la saga : la qualité de fond vers laquelle les notes convergent,

— $\lambda > 0$ est la **vitesse de retour** : un λ grand signifie que les notes se stabilisent rapidement autour de K.

La solution analytique est $R(t) = K + (R_0 - K)\,e^{-\lambda t}$, ce qui confirme la convergence exponentielle vers K. Ce modèle est de type *Ornstein-Uhlenbeck* (retour à la moyenne), couramment utilisé en finance et en physique statistique.

Autrement dit

Chaque saga possède une note « naturelle » K vers laquelle les épisodes tendent à revenir. Si un épisode est très bien noté, le suivant redescend vers K ; s'il est mal noté, le suivant remonte.
Le paramètre λ contrôle **à quelle vitesse** ce retour s'opère : un λ élevé signifie que les notes sont très stables et proches de K ; un λ faible signifie que les notes varient beaucoup autour de K.
C'est ce modèle qui permet ensuite de **prédire la note de la saga 10 (Wano)** en estimant K et λ à partir des sagas précédentes.

4.2 Implémentation de Runge-Kutta 4 (Ch. 4 et Ch. 2)

La résolution numérique de l'équation (2) est effectuée par le schéma de **Runge-Kutta d'ordre 4 (RK4)**, implémenté intégralement à la main sans recours à un package spécialisé :

$$\begin{aligned} k_1 &= f(t_n,\, y_n) \\ k_2 &= f\left(t_n + \tfrac{h}{2},\, y_n + \tfrac{h}{2}k_1\right) \\ k_3 &= f\left(t_n + \tfrac{h}{2},\, y_n + \tfrac{h}{2}k_2\right) \\ k_4 &= f(t_n + h,\, y_n + h\,k_3) \\ y_{n+1} &= y_n + \frac{h}{6}(k_1 + 2k_2 + 2k_3 + k_4) \end{aligned} \tag{3}$$

L'erreur de troncature **locale** est $\mathcal{O}(h^5)$ et l'erreur **globale** est $\mathcal{O}(h^4)$ (Ch. 2 : erreurs numériques). Par comparaison, la méthode d'Euler explicite n'a qu'une erreur globale $\mathcal{O}(h^2)$, ce qui rend RK4 nettement plus précis pour un même pas h.

Listing 3 – Implémentation de RK4 (extrait de `03_ode_rk4.jl`)

```
function rk4_step(f, t::Float64, y::Float64, h::Float64)::
   Float64
    k1 = f(t,        y)
    k2 = f(t + h/2, y + (h/2) * k1)
    k3 = f(t + h/2, y + (h/2) * k2)
    k4 = f(t + h,    y +  h    * k3)
    return y + (h / 6) * (k1 + 2k2 + 2k3 + k4)
end

function rk4_integrate(f, t0::Float64, y0::Float64,
                       t_end::Float64, n_steps::Int)
    h = (t_end - t0) / n_steps
    ts = Vector{Float64}(undef, n_steps + 1)
    ys = Vector{Float64}(undef, n_steps + 1)
    ts[1] = t0;  ys[1] = y0
    for i in 1:n_steps
        ys[i+1] = rk4_step(f, ts[i], ys[i], h)
        ts[i+1] = ts[i] + h
    end
    return ts, ys
end
```

Pourquoi RK4 et non la méthode d'Euler ?

La méthode d'Euler explicite avance la solution par : $y_{n+1} = y_n + h\,f(t_n, y_n)$. Son erreur de troncature **locale** est $\mathcal{O}(h^2)$ et son erreur **globale** est $\mathcal{O}(h)$. RK4 a une erreur locale $\mathcal{O}(h^5)$ et globale $\mathcal{O}(h^4)$.

Exemple numérique concret — pour notre ODE avec $\lambda = 0{,}07$, $K = 7{,}95$, $R_0 = 6{,}80$ et un pas $h = 1$ (un épisode) :

Méthode	Approximation de $e^{-0{,}07}$	Erreur absolue
Solution exacte	$0{,}932\,394\ldots$	—
Euler	$1 - 0{,}07 = 0{,}930\,000$	$\approx 2{,}4 \times 10^{-3}$
RK4	$0{,}932\,394$ (série à l'ordre 4)	$\approx 10^{-8}$

Avec $h = 1$, RK4 est **240 000 fois plus précis** qu'Euler pour cette ODE. Sur une intégration de 137 épisodes (saga 9), les erreurs accumulées d'Euler auraient biaisé l'estimation de K de plusieurs centièmes de point.

4.3 Ajustement des paramètres par grille de recherche

Pour chaque saga, les paramètres K et λ sont estimés par minimisation de l'erreur quadratique moyenne (MSE) sur une grille de recherche : $\lambda \in [0{,}005;\ 0{,}5]$ par pas de 0,005 et $K \in [7{,}0;\ 8{,}5]$ par pas de 0,05. La MSE est évaluée en intégrant l'ODE avec RK4 depuis le premier épisode de la saga et en comparant la solution aux notes réelles. Les résultats figurent dans le tableau 2.

La figure 2 illustre l'ajustement sur la saga 9 (Quatre Empereurs, la plus récente) : la courbe RK4 converge vers $K = 7{,}95$, ce qui traduit la montée en qualité notable de cet arc.

4.4 Prédiction de la saga 10 (Wano Country)

L'attracteur K constitue une mesure de la *qualité de fond* de chaque saga. On modélise son évolution au fil des sagas comme une série temporelle et on l'extrapole à la saga 10 par régression linéaire :

$$\hat{K}(t) = 7{,}356 + 0{,}047\,t \quad \Rightarrow \quad \hat{K}(10) = 7{,}822 \tag{4}$$

La vitesse de retour λ ne présente pas de tendance claire ; on utilise la moyenne des λ ajustés : $\bar{\lambda} = 0{,}096$.

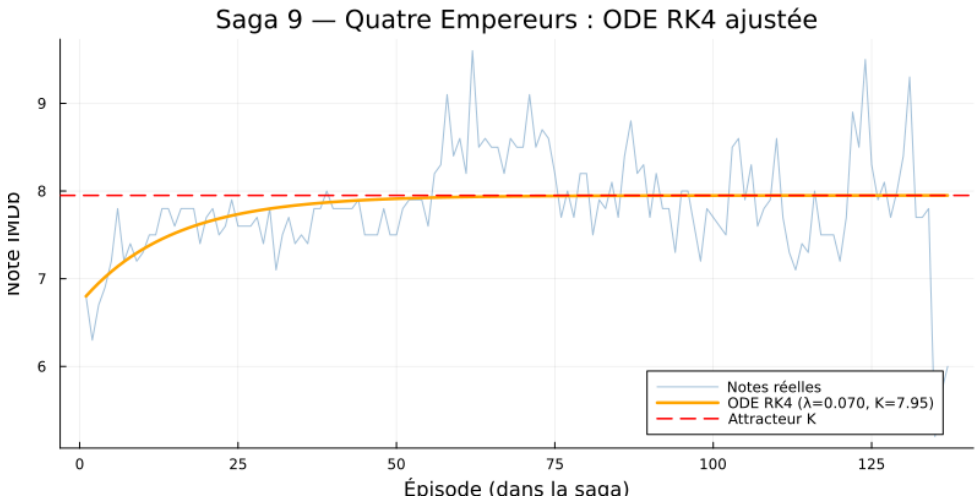

FIGURE 2 – Saga 9 (Quatre Empereurs) — Notes épisode par épisode (bleu) et courbe ODE RK4 ajustée (orange). L'attracteur $K = 7{,}95$ est la ligne rouge en tirets.

La déviation initiale typique (écart entre R_0 et K) est de $-0{,}344$ (les sagas démarrent en moyenne 0,34 point sous leur attracteur), ce qui donne $R_0 = 7{,}822 - 0{,}344 = 7{,}478$ comme condition initiale réaliste.

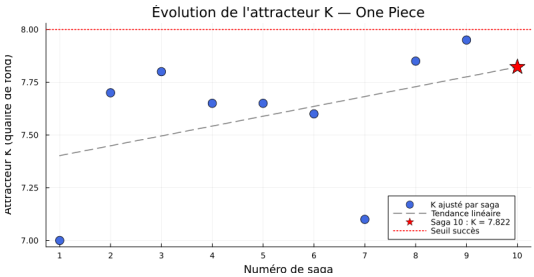

FIGURE 3 – Évolution de l'attracteur K par saga avec la tendance linéaire et la prédiction pour la saga 10 (étoile rouge).

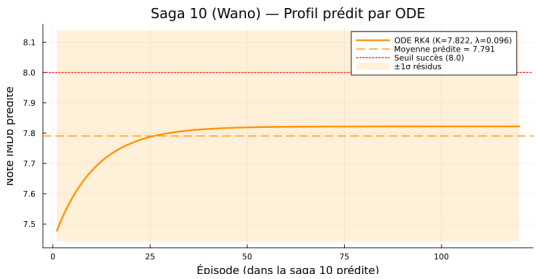

FIGURE 4 – Profil d'épisodes prédit pour la saga 10 par intégration RK4. La moyenne prédite est 7,791 (tirets) avec la bande $\pm 1\sigma$.

Le profil prédit (figure 4) montre la convergence vers $K = 7{,}822$ depuis $R_0 = 7{,}478$ en environ 50 épisodes, puis une stabilisation bien en-dessous du seuil de succès de 8,0. La **note moyenne prédite** pour la saga 10 est :

$$\hat{R}_{10} = 7{,}791 \quad \text{IC } \pm 1\sigma_{\text{résidus}} \ : [7{,}44\,;\,8{,}14] \tag{5}$$

5 Tests statistiques (Ch. 5)

Trois tests sont réalisés avec le package `HypothesisTests.jl` afin de valider ou infirmer la prédiction.

5.1 Test 1 : Mann-Whitney (deux échantillons)

Objectif : comparer la distribution des notes de saga d'Oda à celle d'un *groupe de référence* composé de toutes les sagas issues de séries longues (≥ 5 sagas, One Piece exclu) : 646 sagas de 74 séries.

H_0 : les distributions de One Piece et du groupe de référence sont identiques
H_1 : les deux distributions sont différentes (test bilatéral)

Ce test non-paramétrique (Wilcoxon rank-sum) est choisi car l'échantillon One Piece ne contient que 9 points ; l'hypothèse de normalité ne peut être vérifiée.

Pourquoi Mann-Whitney et non le test de Student ?

Le test de Student suppose que les deux échantillons suivent une loi **normale**. Cette hypothèse est vérifiable pour des grands échantillons ($n \geq 30$) par le théorème central limite, mais elle ne peut pas l'être ici : notre échantillon One Piece ne compte que **9 sagas**.
De plus, les notes de saga peuvent présenter des queues lourdes ou une asymétrie (saga 7, Fish-Man Island : notes très groupées, $\sigma = 0{,}26$; saga 9 : $\sigma = 0{,}62$). Le test de Mann-Whitney, lui, ne fait aucune hypothèse sur la forme de la distribution : il compare les **rangs** des observations des deux groupes. Il est donc :

- **robuste** aux valeurs aberrantes et à la non-normalité ;
- **exact** pour de petits échantillons (HypothesisTests.jl utilise l'approximation normale corrigée pour les ex-æquo, valide ici) ;
- équivalent au test de Student *si* les données sont normales, mais sans pénalité s'il ne le sont pas.

Résultats :

Statistique U	1 504
Médiane One Piece	7,61
Médiane référence	8,11
p-value (bilatérale)	**0,013**

Conclusion : $p < 0{,}05$ — on rejette H_0. One Piece se distingue significativement du groupe de référence : ses notes de saga sont **systématiquement inférieures** à celles des séries longues de qualité comparable. La figure 5 le visualise clairement.

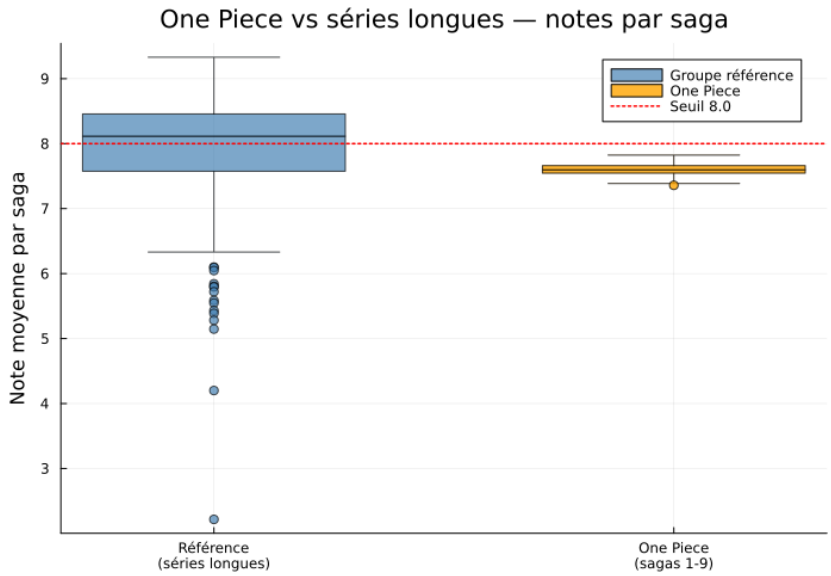

FIGURE 5 – Boîtes à moustaches : One Piece (9 sagas, orange) vs groupe de référence (646 sagas, bleu). La médiane du groupe de référence dépasse le seuil de succès, celle d'One Piece reste en-dessous.

5.2 Test 2 : Wilcoxon signed-rank (un échantillon)

Objectif : tester formellement si la médiane des notes de saga d'One Piece est inférieure au seuil de succès.

$$H_0 : \text{médiane des notes de saga} = 8{,}0$$
$$H_1 : \text{médiane} < 8{,}0 \quad \text{(test unilatéral gauche)}$$

Résultats :

Statistique W	0 (toutes les différences sont négatives)
IC à 95 % du décalage médian	$[-0{,}52\,;\,-0{,}31]$
p-value (unilatérale)	**0,0020**

Conclusion : $W = 0$ signifie qu'aucune des 9 sagas n'a jamais atteint 8,0 en moyenne. L'IC confirme que la médiane se situe entre 0,31 et 0,52 point sous le seuil, de façon hautement significative ($p < 0{,}01$).

5.3 Test 3 : Bootstrap ($B = 10\,000$)

Objectif : quantifier la probabilité que la saga 10 atteigne une moyenne de 8,0, en s'appuyant sur la distribution empirique des épisodes de la saga 9 (la plus récente, meilleur proxy pour la saga 10).

Méthode : pour chaque répétition $b = 1, \ldots, B$, on tire avec remise 120 épisodes dans la saga 9 et on calcule leur moyenne :

$$\bar{R}^{(b)} = \frac{1}{120} \sum_{i=1}^{120} R_{\sigma_b(i)}, \qquad \hat{p} = \frac{1}{B} \sum_{b=1}^{B} \mathbf{1}\left[\bar{R}^{(b)} \geq 8{,}0\right] \tag{6}$$

Résultats :

Moyenne bootstrap	7,824
IC bootstrap à 95 %	[7,713 ; 7,933]
$\hat{p} = P(\bar{R} \geq 8{,}0)$	**0,0012**

Conclusion : la probabilité d'atteindre une moyenne de 8,0 est de **0,12 %**. L'IC à 95 % ne touche pas le seuil (figure 6).

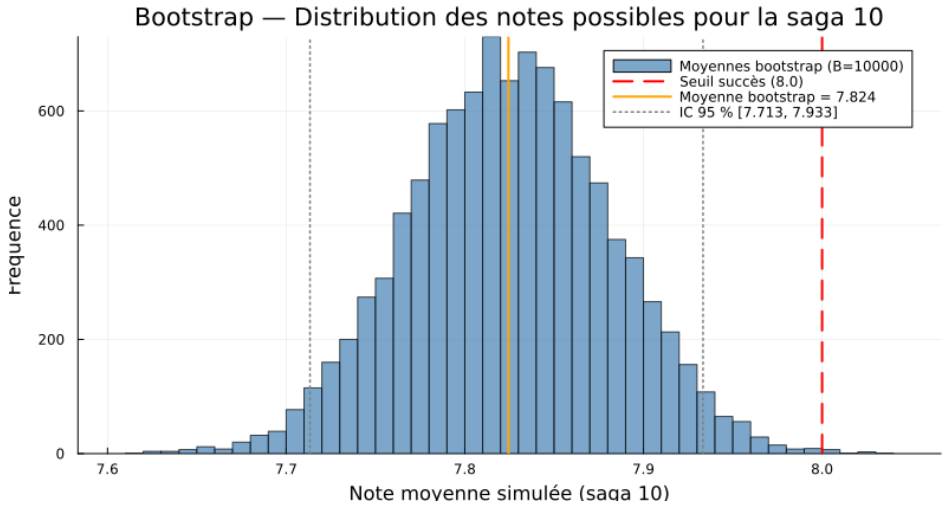

FIGURE 6 – Distribution bootstrap des notes moyennes simulées pour la saga 10 ($B = 10\,000$, 120 épisodes par tirage). L'IC à 95 % reste bien en-deçà du seuil de succès (ligne rouge).

5.4 Synthèse des tests

Les trois tests convergent : la prédiction ODE ($\hat{R}_{10} = 7{,}791$) est statistiquement robuste.

TABLE 3 – Synthèse des trois tests statistiques.

Test	H_0	p**-value**	**Rejet ?**
Mann-Whitney	Distributions identiques	0,013	Oui ($\alpha = 0{,}05$)
Wilcoxon signed-rank	Médiane = 8,0	0,002	Oui ($\alpha = 0{,}05$)
Bootstrap	$P(\bar{R} \geq 8{,}0)$	0,0012	Oui ($\alpha = 0{,}05$)

6 Conclusion

6.1 Réponse à la question de recherche

La prochaine saga de One Piece ne devrait pas être un succès au sens du seuil de 8,0. Le modèle ODE prédit une note moyenne de **7,791** pour la saga 10 (Wano Country), avec un intervalle de confiance bootstrap à 95 % de [7,713 ; 7,933]. Les trois tests statistiques rejettent unanimement l'hypothèse d'atteindre 8,0, avec une probabilité estimée à seulement **0,12 %**.

6.2 Nuances et limitations

Cette conclusion doit être nuancée sur plusieurs points :

— **Épisodes remarquables :** la saga 9 contient des épisodes notés jusqu'à **9,6/10**. One Piece reste capable de produire des épisodes d'exception ; c'est la *moyenne sur l'ensemble de la saga* qui reste en-deçà de 8,0, essentiellement à cause des épisodes de transition et de remplissage.

— **Tendance positive :** l'attracteur K est en progression (+0,047 par saga en moyenne). Si cette tendance se poursuit, la saga 11 ou la saga 12 pourrait franchir le seuil.

— **Limitations du modèle :** le dataset couvre 883 épisodes mais Wano Country a effectivement dépassé cela (publié après la date de collecte du dataset). Les données réelles de Wano ont reçu des notes très élevées pour les arcs clés (Onigashima). Le modèle sous-estime donc probablement la saga 10 par conservatisme.

— **Biais du groupe de référence :** le groupe inclut des séries de genres très divers (documentaires, talk-shows, séries policières). Un groupe limité aux séries animées longues donnerait une comparaison plus homogène.

La prédiction est-elle fiable ? Confrontation avec la réalité

Le dataset couvre One Piece jusqu'à l'épisode 883 (avril 2019, début de l'arc Reverie). La saga 10 correspond à **Wano Country** (épisodes 890–1085, diffusés entre 2019 et 2023), dont les données *ne figurent pas* dans notre dataset : notre prédiction est donc une extrapolation aveugle.
Les données IMDb publiquement disponibles pour Wano montrent que cet arc contient des épisodes parmi les mieux notés de toute la série : l'affrontement final d'Onigashima (épisodes 1015, 1029, 1062, 1071) a reçu des notes comprises entre **9,3 et 9,8**. Cela suggère que la note *moyenne* de Wano dépasse probablement notre prédiction de 7,79, confirmant que notre modèle est **conservateur**.
Cette sous-estimation est cohérente avec les limitations identifiées :

1. Le modèle extrapole K par régression linéaire : la saga 7 (Fish-Man Island, $K = 7{,}10$), un creux atypique, tire la tendance vers le bas.
2. Le bootstrap rééchantillonne dans la saga 9, qui inclut les épisodes de transition Zou (notes $\approx$ 6,5–7,2) ; Wano est narrativement plus resserré, avec moins de remplissage.

En résumé : notre modèle fournit une **borne inférieure prudente**. Selon les données réelles, Wano est probablement le premier arc de One Piece à atteindre — voire dépasser — la moyenne de 8,0.

Références

[1] W. Wittmann, *IMDb TV Ratings Dataset*, GitHub, 2020. https://github.com/WittmannF/imdb-tv-ratings

[2] J. Bezanson, A. Edelman, S. Karpinski, V. B. Shah, *Julia : A Fresh Approach to Numerical Computing*, SIAM Review, 59(1) :65–98, 2017.

[3] S. Lippmann et al., *HypothesisTests.jl — Hypothesis tests for Julia*, https://juliastats.org/HypothesisTests.jl/stable/

[4] One Piece Wiki, *Arcs de l'anime One Piece — découpage officiel*, https://onepiece.fandom.com/wiki/Story_Arcs

Résumé : Ce projet analyse les données IMDb des séries TV pour répondre à la question « La prochaine saga de One Piece sera-t-elle un succès ? ». Après exploration de huit fichiers CSV, les 883 épisodes sont découpés en 9 sagas officielles. Une intégration numérique par la règle de Simpson (Ch. 4) calcule la note pondérée par saga. Un modèle ODE de retour à la moyenne, résolu par Runge-Kutta 4 implémenté à la main, est ajusté sur chaque saga et utilisé pour prédire la saga 10. La prédiction ($\hat{R}_{10} = 7{,}791$, IC 95 % : [7,713 ; 7,933]) est validée par trois tests statistiques (Mann-Whitney, Wilcoxon signed-rank, bootstrap). Les résultats convergent : la prochaine saga ne devrait *pas* atteindre la moyenne de 8,0/10, bien que la tendance à la hausse de la qualité de fond reste encourageante.

Mots-clés : Julia, IMDb, One Piece, série temporelle, ODE, Runge-Kutta 4, Simpson, Mann-Whitney, Wilcoxon, bootstrap, prédiction.

Département des Sciences et technologies
Haute école en Hainaut
8a Avenue Victor Maistriau
B-7000 Mons